


6 Predobdelave podatov

6.1 Normalizacija in standardizacija


Normalizacija in standardizacija

- Najpogostejše uporabljeni predobdelavi/transformaciji
- Po predobdelavi → spremenljivke bolj primerljive, vidni vzorci
- Transformacija = predobdelava = ang. pre-treatment


Dejanski podatki



Standardizacija



Normalizacija



Normalizacija	Standardizacija
min-max-scaling	z-vrednosti (ang. z-scores)
$x_{i,norm} = \frac{x_i - x_{min}}{x_{max} - x_{min}}$	$z_i = \frac{x_i - \mu}{\sigma}$
Za transformacijo se uporabi min in max	Za transformacijo se uporabi μ in σ
Vrednosti se transformirajo na interval [0, 1]	Vrednosti se transformirajo v spremenljivko s povprečjem 0 in standardnim odklonom 1
Metoda je zelo občutljiva na osamelce	Metoda ni občutljiva na osamelce
Uporabna je, kadar ne poznamo oblike porazdelitve	Uporabna je za normalno porazdeljene spremenljivke
Nima vsebinskega pomena	• Predznak: ali je enota nad (+) ali pod (-) povprečjem. • Absolutna vrednost: za koliko standardnih odklonov se vrednost odklanja od povprečja

SPSS primer

- 1) Standardizirajte spremenljivko *Income* v podatkih [streaming_platforms.sav](#) in interpretirajte eno pozitivno in eno negativno vrednost.
 - 2) Normalizirajte spremenljivko *Income* v podatkih [streaming_platforms.sav](#).
- Za izračun povprečja, standardnega odklona, min in max uporabimo:

Analyze – Descriptive statistics – Frequencies

- Za izračun transformiranih spremenljivk uporabimo:

Transform – Compute variable

Statistics

Dohodek


N	Valid	200
	Missing	0
Mean		1930,09
Std. Deviation		895,123
Minimum		648
Maximum		3955

 ID	 normalizacija	 standardizacija	 Income
1	,60	,78	2624
2	,87	1,77	3510
3	,58	,71	2562
4	,80	1,52	3290
5	,50	,42	2309
6	,35	-,14	1801
7	,23	-,57	1416
8	,08	-1,12	925
9	,26	-,47	1505
10	,55	,59	2461
11	,08	-1,15	904
12	,86	1,73	3479
13	,41	,09	2007
14	,87	1,79	3532

Interpretacija

Dohodek osebe z id = 11 je za 1,15 standardnega odklona pod povprečnim dohodkom vzorca.

Dohodek osebe z id = 12 je za 1,73 standardnega odklona nad povprečnim dohodkom vzorca.



**Histogram originalne,
standardizirane in normalizirane
spremenljivke.**

