


18 Linearna regresija

18.1 Vzorčna regresijska premica


Regresija

Kako med točke v razsevnem grafikonu vrisati krivuljo (npr. premico), da bo najbolje ponazarjala odvisnost med spremenljivkama?


Šibka pozitivna
linearna povezanost




Srednje močna pozitivna
linearna povezanost



Močna negativna
linearna povezanost



Ni linearne
povezanosti



Tipi regresijske analize glede na število spremenljivk:

- **Bivariatna regresija:** ena odvisna spremenljivka $\leftarrow$ ena neodvisna spremenljivka

ODVISNA SPREMENLJIVKA: Cena stanovanja

NEODVISNA SPREMENLJIVKA: Površina stanovnja (m^2)

- **Multipla regresija:** ena odvisna spremenljivka $\leftarrow$ več neodvisnih

ODVISNA SPREMENLJIVKA: cena stanovanja


NEODVISNE SPREMENLJIVKE:

- Površina stanovnja (m^2)
- Število sob
- Oddaljenost od centra
- Starost stanovanja

Tipi regresijske analize glede na obliko regresijske funkcije:


- **Linearna regresija:**

regresijska funkcija je linearna.



- **Nelinearna regresija:**

regresijska funkcija ni linearna.



Bivariatna linearna regresija (ang. simple linear regression)


Postopek regresijske analize

1. **Razsevni grafikon:** ugotovimo, ali obstaja linearna povezanost.
2. **Vzorčna regresijska premica:** poiščemo premico, ki se vzorčnim podatkom najbolj prilega
3. **Sklep o populaciji:** iz vzorčnih podatkov sklepamo o regresiji med spremenljivkama na populaciji
4. **Napoved:** s pomočjo premice lahko napovedujemo vrednosti odvisne spremenljivke Y s pomočjo vrednosti neodvisne spremenljivke X .
5. **Kakovost pojasnjevanja** odvisnosti ocenimo z **determinacijskim koeficientom** R^2 ,
kakovost napovedovanja vrednosti pa s **standardno napako ocene**.


1. Razsewni grafikon

Naloga: Za vsakega od šestih grafov določite:


- moč povezave: **a) šibka, b) zmerna c) močna**
- ali bi bila uporaba linearnega modela smiselna? **a) da b) ne**




(a)




(b)




(c)



(d)



(e)



(f)

“Essentially, all models are wrong, but some are useful”

George Box


2. Vzorčna regresijska premica – premica, ki se podatkom najbolj prilega po metodi najmanjših kvadratov (ang. OLS, ordinary least squares)

$$\hat{Y} = a + bX$$

$$Y = \hat{Y} + E = a + bX + E$$

oz. za i -to enoto:

$$y_i = \hat{y}_i + e_i = a + bx_i + e_i$$



Pomembno: $T(\bar{x}, \bar{y})$ vedno leži na vzorčni regresijski premici

Grafično: Regresijska premica je med točke v razsevnem grafikonu postavljena tako, da so odkloni točk od premice čim manjši.

Matematično: Regresijska premica je določena z metodo najmanjših kvadratov: vsota kvadratnih odklonov dejanskih vrednosti od premice je najmanjša.

https://phet.colorado.edu/sims/html/least-squares-regression/latest/least-squares-regression_en.html

Za natančno izpeljavo cenilk koeficientov si lahko pogledate:

<https://mathworld.wolfram.com/LeastSquaresFitting.html>

Metoda najmanjših kvadratov

$$\begin{aligned} F(a, b) &= \sum_i^n e_i^2 = \\ &= \sum_i^n (y_i - \hat{y}_i)^2 = \\ &= \sum_i^n (y_i - a - bx_i)^2 \end{aligned}$$

$$\min \left(F(a, b) = \sum_i^n (y_i - a - bx_i)^2 \right)$$

- Funkcijo F parcialno odvajamo po a in po b .
- Odvoda enačimo z nič.
- Rešimo sistem dveh enačb z neznankama a in b .
- Rešitev je:


$$\begin{aligned} b &= \frac{S_{XY}}{s_X^2} \\ a &= \bar{y} - b\bar{x}, \end{aligned}$$

$s_{XY} = \frac{1}{n-1} \sum_i^n (x_i - \bar{x})(y_i - \bar{y})$ je **vzorčna kovarianca**,

$s_X^2 = \frac{1}{n-1} \sum_i^n (x_i - \bar{x})^2$ je **vzorčna varianca** spremenljivke X .

Primer

Za 8 slučajno izbranih oseb imamo podatke o številu let izobrazbe (X) in številu ur branja časopisov na teden (Y). Podatki: [izobrazba-branje-regresija.sav](#)



Za izračun vzorčne regresijske premice ne rabi biti izpolnjena nobena predpostavka.

*Postopek: Graphs > Legacy Dialogs > Scatter/Dot > Simple Scatter > Y Axis: branje, X Axis: izobrazba
Dvoklik na graf, da se odpre Chart Editor > Add Fit Line At Total*

Vsebinski pomen regresijske premice $\hat{y} = a + bx$

Za naš primer: $\hat{y} = -0,69 + 0,46x$

1) **Konstanta** a je presečišče z y osjo: kakšna je vrednost spremenljivke y pri $x = 0$.

Primer: koliko ur berejo dnevne časopise na teden tisti, ki imajo število let izobrazbe 0?

$a = -0,69$ ure na teden. To v našem primeru ni smiselno. **Napovedi izven obsega vzorčnih podatkov niso smiselne!**

2) **Regresijski koeficient** b določa naklon premice in pove, za koliko se spremeni vrednost y , če se x spremeni za eno enoto. Če je $b = 0$, potem y ni odvisna od x .

Primer: Z vsakim letom izobrazbe več se število ur branja dnevnih časopisov na teden v povprečju poveča za $b = 0,46$ ure. Ker je $b > 0$ ima dolžina izobrazbe pozitiven vpliv na čas branja: tisti, ki imajo več let izobrazbe, berejo več ur na teden.

Napoved

Za naš primer: $\hat{y} = -0,69 + 0,46x$


Koliko ur na teden pričakujemo da bo brala oseba z 8 let izobrazbe?

Koliko ur na teden pričakujemo da bo brala oseba s 30 let izobrazbe?

Koliko ur na teden pričakujemo da bo brala oseba z 0 let izobrazbe?

NAPOVEDI SO SMISELNE LE V MEJAH PODATKOV!!!

Na
komponente
razdeljena
variabilnost je
osnova za
izračun
determinacijske
ga koeficienta.




Variabilnost ocenjujemo s povprečnimi vsotami kvadratov

$$\sum_{i=1}^N (y_i - \bar{y})^2 = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^N (y_i - \hat{y}_i)^2$$
$$SS_{total} = SS_{model} + SS_{error}$$

SS_T = skupna variabilnost


SS_M = z modelom pojasnjena variabilnost

SS_E = nepojasnjena variabilnost





Skupna variabilnost

$$SS_T = \sum_{i=1}^n (y_i - \bar{y})^2$$




Nepojasnjena variabilnost

$$SS_E = \sum_{i=1}^N (y_i - \hat{y}_i)^2$$




Ocenite SS_M , SS_E , SS_T za oba grafikona.



Spremenljivka X ni odvisna od spremenljivke Y.
Vzorčna regresijska premica:

$$\begin{aligned}\hat{Y} &= 5 \\ \hat{Y} &= \bar{Y} \\ SS_M &= 0 \\ SS_E &= 0 \\ SS_T &= 0\end{aligned}$$



Spremenljivka X ni odvisna od spremenljivke Y.
Vzorčna regresijska premica:

$$\begin{aligned}\hat{Y} &= 5 \\ \hat{Y} &= \bar{Y} \\ SS_M &= 0 \\ SS_E &> 0 \\ SS_T &= SS_E\end{aligned}$$

Determinacijski koeficient R^2 = delež pojasnjene variabilnosti

Z modelom pojasnjena variabilnost

$$SS_M = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2$$

$$SS_T = \sum_{i=1}^n (y_i - \bar{y})^2$$





Skupna variabilnost

Nepojasnjena variabilnost



$$SS_E = \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

$$SS_T = \sum_{i=1}^n (y_i - \bar{y})^2$$

Skupna variabilnost




Standardna napaka ocene (RMSE) = standardni odklon napak e_i



Na kateri sliki bodo napovedi z regresijsko premico natančnejše?

Napaka napovedi



Standardna napaka ocene $RMSE$ = standardni odklon napak e_i

Populacijska standardna napaka ocene σ_e

$$\sigma_e = \sqrt{\frac{1}{N} \cdot \sum_{i=1}^N (e_i)^2} = \sqrt{\frac{1}{N} \cdot \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Vzorčna standardna napaka ocene s_e

$$s_e = RMSE = \sqrt{\frac{1}{n-2} \cdot \sum_{i=1}^N (e_i)^2} = \sqrt{\frac{1}{n-2} \cdot \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

RMSE = Root Mean Square Error = (Kvadratni) Koren Povprečne Kvadrirane Napake

Pove nam:

→ Povprečni odklon dejanskih vrednosti y_i od napovedanih vrednosti $\hat{y}_i$.

Želimo, da je standardna napaka čim manjša = da so odkloni od regresijske krivulje čim manjši.

Naši podatki

Postopek: Analyze > Regression > Linear > Dependent: branje, Independent: izobrazba

Model Summary				
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,923 ^a	,852	,827	,80064
a. Predictors: (Constant), Število let izobrazbe				

R je (pri bivariatni regresiji) vzorčni Pearsonov korelacijski koeficient.

Njegov pomen smo spoznali v poglavju (16.2.) o povezanosti.

R Square (R^2) je determinacijski koeficient = delež pojasnjene variance

$R^2 = 0,852$, kar pomeni, da je 85 % variabilnosti spremenljivke branje pojasnjene s spremenljivko izobrazba.

Model Summary				
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,923 ^a	,852	,827	,80064
a. Predictors: (Constant), Število let izobrazbe				

V primeru več odvisnih spremenljivk (multivariatna regresija) se za oceno pojasnjene variabilnosti uporabi prilagojeni R^2 (ang. Adjusted R Square).

Standardna napaka ocene (ang. Standard Error of Estimate) = standardni odklon ostankov = koliko so v povprečju opazovane točke odmaknjene od ocenjene regresijske premice.

$s_e = 0,80$. To pomeni, če bi za opazovane (vzorčne enote) izračunali število ur branja dnevnih časopisov na teden s pomočjo ocenjene regresijske premice in podatkov o številu let izobrazbe, bi v povprečju naredili napako za 0,8 ure.