


18.2 Ocenjevanje linearnega regresijskega modela

Populacijski regresijski model



Vzorčni regresijski model:

$$Y = a + bX + E$$

Sklepanje iz vzorca na populacijo – inferenčna statistika za regresijsko analizo



Vzorčna regresijska premica:

$$\hat{Y} = a + bX$$

Populacijska regresijska premica:

$$\hat{Y} = \alpha + \beta X$$

Kaj lahko iz vzorca sklepamo o populacijski regresijski premici?



Vsaka premica najmanjših kvadratov je nekoliko drugačna, vendar so v povprečju te premice zelo blizu populacijski regresijski premici populacije.

Rdeča črta (levo in desno) je prava (populacijska) regresijska premica: $f(X) = 2 + 3X$.

Temno modra črta (levo in desno) je **premica najmanjših kvadratov** izračunana iz vzročnih podatkov, prikazanih s črnimi točkami.

Svetlo modre črte predstavljajo deset premic najmanjših kvadratov, izračunanih iz desetih naključnih vzorcev.

Predpostavke inferenčne statistike za regresijsko analizo

1) Neodvisnost: enote so vzorčene naključno in neodvisno

(Preveriti je iz podatkov vedno ne moremo. Izberemo pravilno vzorčenje ali poskusno zasnovo.)

2) Linearnost: povezanost med spremenljivkama X in Y je linearna

(Narišemo razsevni grafikon)

3) Homoskedastičnost: varianca porazdelitve ostankov je enaka pri vsaki vrednosti spr. X

(Narišemo graf ostankov: x-os: $\hat{y}$ — napovedane vrednosti, y-os: ostanki)

Postopek: Analyze > Regression > Linear > Dependent: branje, Block: izobrazba > Plots >

X: ZPRED, Y:ZRESID


4) Normalnost: ostanki morajo biti normalno porazdeljeni z povprečjem 0: $N(0, \sigma)$

(Narišemo histogram in/ali PP-grafikon ostankov.)

Postopek: Analyze > Regression > Linear > Dependent: branje, Block: izobrazba > Plots > Histogram,

Normal probability plot

Razsevni grafikoni




Grafikon ostankov

Za vsakega od zgornjih primerov ugotovite ali je kršena predpostavka o

- a) Neodvisnosti
- b) Linearnosti
- c) Homoskedastičnosti
- d) Normalnosti

Primer: Preverjanje predpostavk

Razsevni grafikon – linearnost





Primer: Preverjanje predpostavk

PP-graf, histogram– normalnost ostankov




Normal P-P Plot of Regression Standardized Residual
Dependent Variable: Število ur branja dnevnih časopisov na teden



Primer: Preverjanje predpostavk

Graf ostankov – homoskedastičnost, normalnost, osamelci, odvisnost



Test koeficienta α (presečišče z y-osjo/konstanta)

Ničelna hipoteza:

$$\alpha = \alpha_0$$

Alternativna hipoteza:

$$\alpha \neq \alpha_0$$

Predpostavke:

**Predpostavke inferenčne statistike za
regresijsko analizo (na prejšnjih straneh)**

Postopek v SPSS:

Analyze > Regression > Linear

Postopek računanja testne statistike:

$$t = \frac{\alpha - \alpha_0}{SE(\alpha)} \sim T(n - 2)$$

OPOMBA Ta test običajno nima vsebinskega pomena.

Test regresijskega koeficienta β

Ničelna hipoteza:

$$\beta = \beta_0$$

Alternativna hipoteza:

$$\beta \neq \beta_0$$

Predpostavke:

**Predpostavke inferenčne statistike za
regresijsko analizo (na prejšnjih straneh)**

Postopek v SPSS:

Analyze > Regression > Linear

Postopek računanja testne statistike:

$$t = \frac{b - \beta_0}{SE(\beta)} \sim S(n - 2)$$

OPOMBA Ta test, nam da odgovor o tem, ali ima neodvisna spremenljivka vpliv na odvisno.

Primer SPSS

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	22,154	1	22,154	34,560	,001 ^b
	Residual	3,846	6	,641		
	Total	26,000	7			

a. Dependent Variable: Število ur branja dnevnih časopisov na teden

b. Predictors: (Constant), Število let izobrazbe

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	-,692	,689		-1,005	,354
	Število let izobrazbe	,462	,079	,923	5,879	,001

a. Dependent Variable: Število ur branja dnevnih časopisov na teden

V primeru bivariatne regresije je ničelna hipoteza, testirana v tabeli ANOVA in tabeli Coefficients enaka. Testa vrnete skladne rezultate. Zato tabele ANOVA v našem(bivariatnem) primeru ni potrebno interpretirati. V primeru več odvisnih spremenljivk pa ima tabela ANOVA bistven pomen.

Primer SPSS – interpretacija tabele Coefficients – koeficienti B

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	-,692	,689		-1,005	,354
	Število let izobrazbe	,462	,079	,923	5,879	,001

a. Dependent Variable: Število ur branja dnevnih časopisov na teden

Iz stolpca B preberemo oba koeficienta vzorčne regresijske premice $\hat{y} = a + bx$:

a = Constant

b = regresijski koeficient = Število let izobrazbe

Število ur branja dnevnih časopisov = $-0,692 + 0,462 \cdot \text{Število let izobrazbe}$

Primer SPSS – tabela Coefficients – standardne napake koeficientov

		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
Model		B	Std. Error	Beta		
1	(Constant)	-,692	,689		-1,005	,354
	Število let izobrazbe	,462	,079	,923	5,879	,001

Iz stolpca *Standardna napaka* (ang. Std. Error) preberemo standardno napako vsakega od koeficientov regresijske premice.

Standardna napaka koeficienta = std. odklon porazdelitve, ki bi jo dobili, če bi iz populacije izbrali vse možne vzorce po $n = 7$ ljudi in bi iz vsakega vzorca ocenili koeficienta regresijske premice.

$$SE(\beta) = \frac{RMSE}{\sqrt{SS_X}} = \frac{\sqrt{\frac{1}{n-2} \cdot \sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

$$SE(\alpha) = SE(\beta) \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$$

Primer SPSS – tabela Coefficients – Standardizirani koeficienti

		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
Model		B	Std. Error	Beta		
1	(Constant)	-,692	,689		-1,005	,354
	Število let izobrazbe	,462	,079	,923	5,879	,001

a. Dependent Variable: Število ur branja dnevnih časopisov na teden

Standardizirane koeficiente (Standardized coefficients Beta) bi dobili, če bi regresijsko premico izračunali na standardiziranih vrednostih odvisne in neodvisne spremenljivke.

Standardizacija spremenljivke X : za vsak i : $\frac{x_i - \bar{x}}{s_x}$

Standardizacija spremenljivke Y : za vsak i : $\frac{y_i - \bar{y}}{s_y}$

Primer SPSS – tabela Coefficients – Test koeficienta α

		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
Model		B	Std. Error	Beta		
1	(Constant)	-,692	,689		-1,005	,354
	Število let izobrazbe	,462	,079	,923	5,879	,001

Ta test običajno nima vsebinskega pomena.

1. $H_0: \alpha = 0$ (presečišče z y-osjo ni različno od 0)
2. $H_1: \alpha \neq 0$ (presečišče z y-osjo je različno od 0)
3. **Ime testa:** Test koeficienta α (presečišča z y-osjo).
4. **Stopnja značilnosti:**

$$\alpha = 0,05$$

5. **Eksperimentalna vrednost testne statistike:**

$$t_e = -1,005$$

Testna statistika: $t = \frac{\alpha}{SE(\alpha)} \sim T(n - 2)$

6. **p-vrednost:** $p = 0,354$

7. **Sklep o hipotezah:**

Ker je $p > \alpha$, H_0 ne zavrnamo

8. **Interpretacija:** Presečišče z y-osjo se statistično značilno ne razlikuje od 0 pri $\alpha = 0,05$.

Povprečno število ur branja dnevnih časopisov pri osebah z 0 let izobrazbe, se statistično značilno ne razlikuje od 0 ur pri $\alpha = 0,05$.

Primer SPSS – tabela Coefficients – test regresijskega koeficienta β !!!

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.
	B	Std. Error	Beta		
1	(Constant)	-,692	,689	-1,005	,354
	Število let izobrazbe	,462	,079	,923	,001

1. $H_0: \beta = 0$ (neodvisna spremenljivka nima vpliva na odvisno)

2. $H_1: \beta \neq 0$ (neodvisna spremenljivka ima vpliv na odvisno spremenljivko)

1. **Ime testa:** Test regresijskega koeficienta

4. **Stopnja značilnosti:** $\alpha = 0,05$

5. **Eksperimentalna vrednost testne statistike:**

$$\text{Testna statistika: } t = \frac{b}{SE(\beta)} \sim T(n - 2)$$

$$t_e = 5,879$$

6. **p-vrednost:** $p = 0,001$

7. **Sklep o hipotezah:**

Ker je $p < \alpha$, H_0 zavrnamo, H_1 sprejmemo

8. **Interpretacija:** Smerni koeficient β se statistično značilno razlikuje od 0; izobrazba ima statistično značilen vpliv na čas branja dnevnih časopisov pri $\alpha = 0,05$

Primer

Predpostavimo, da smo statistični svetovalci, ki jih je najel naročnik, da svetujemo, kako izboljšati prodajo nekega izdelka.

Podatkovna datoteka [advertising.sav](#) vsebuje podatke o prodaji tega izdelka na 200 različnih tržiščih, skupaj s proračuni za oglaševanje izdelka na vsakem od teh tržišč za tri različne medije: **televizijo, radio in časopise.**




Sales – Število prodanih izdelkov v 1000 enotah

TV – Znesek namenjen TV oglaševanju v 1000 EUR

Radio – Znesek namenjen radio oglaševanju v 1000 EUR

Newspaper – Znesek namenjen časopisnemu oglaševanju v 1000 EUR

Narišimo vse tri razsevne grafikone z vzorčnimi regresijskimi premicami.
Odvisna spremenljivka je število prodanih izdelkov (sales).



Za odvisno spremenljivko sales in neodvisno spremenljivko TV naredimo linearno regresijo in preverimo predpostavke regresijskega modela. In shranimo napovedane vrednosti.

Analyze – Regression – Linear – Dependent: Sales – Independent: TV

Plots - x-axis: ZRESID, y-axis: ZPRED

Save – Predicted values

Model Summary^b

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,782 ^a	,612	,610	3,2587

a. Predictors: (Constant), Znesek namenjen TV oglaševanju v 1000 EUR

b. Dependent Variable: Prodaja v 1000 enotah


R-square pove delež z modelom pojasnjene variabilnosti:

61,2 % variance spremenljivke sales (št. prodanih izdelkov) je pojasnjene s spremenljivko TV (znesek namenjen TV oglasom).

Standardna napaka ocene (RMSE): če bi vse vrednosti iz našega vzorca ocenili z regresijsko premico, bi bila povprečna napaka enaka 3,2 tisoč izdelkov.


Histogram


Dependent Variable: Prodaja v 1000 enotah



Normal P-P Plot of Regression Standardized Residual

Dependent Variable: Prodaja v 1000 enotah





Iz slike vidimo, da je predpostavka o homoskedastičnosti (homogenosti varianc) kršena.

Za vajo vseeno nadaljujmo z interpretacijo.

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	3314,618	1	3314,618	312,145	<,001 ^b
	Residual	2102,531	198	10,619		
	Total	5417,149	199			

a. Dependent Variable: Prodaja v 1000 enotah

b. Predictors: (Constant), Znesek namenjen TV oglaševanju v 1000 EUR

Coefficients^a


Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	7,033	,458		15,360	<,001
	Znesek namenjen TV oglaševanju v 1000 EUR	,048	,003	,782	17,668	<,001

a. Dependent Variable: Prodaja v 1000 enotah

- Za koliko se bi v povprečju povečala prodaja izdelka, če bi znesek namenjen za TV oglaševanje povečali za 5 (10, 15) tisoč EUR?
- Kolikšno je pričakovano število prodanih izdelkov, če podjetje za TV oglaševanje porabi 200 tisoč EUR?

Narišimo graf opazovane vrednosti proti pričakovanim vrednostim.

- *Graphs – Scatter/Dot – x: sales, y: PRE_1*



Če bi bila napoved popolnoma natančna bi vse točke ležale na premici $y = x$.