

POVEZANOST IN LINEARNA REGRESIJA

PROBLEM

Podjetje razvija več različnih spletnih aplikacij, ki se uporabljajo v različnih poslovnih okoljih. V podatkovni datoteki *Aplikacije.sav* so zbrani podatki za naključno izbran vzorec aplikacij. Zajeti so tako tehnični podatki (uporabljena baza podatkov, programsko ogrodje, velikost razvojne ekipe) kot tudi kazalniki uspešnosti delovanja aplikacij v produkcijskem okolju (odzivni čas, pogostost napak, poslovna pomembnost).

Naša tokratna naloga je, da z analizo teh podatkov preverimo, kateri dejavniki so medsebojno povezani.

NALOGE

1. Najprej se spoznajmo s problemom tako, da odgovorimo na naslednja vprašanja.
 - (a) Kaj so v tej razsikavi preučevane statistične enote?
 - (b) Ali je raziskava izvedena na vzorcu ali na populaciji?
 - (c) Koliko enot in koliko spremenljivk vsebuje podatkovna datoteka? Katere so te spremenljivke in kakšne merske lestvice imajo?
2. Ali izbira baze podatkov vpliva na pomembnost aplikacije za poslovanje?
 - (a) Prikaži strukturo ocene pomembnosti aplikacij iz vzorca za poslovanje, in sicer za vsako vrsto baze podatkov posebej. Rezultate prikaži še s strukturnimi stolpci.
 - (b) Ali obstajajo vidne razlike med skupinami?
 - (c) Na stopnji značilnosti 0.10 preveri, ali obstaja povezava med vrsto baze podatkov, ki jo aplikacija uporablja, in oceno pomembnosti aplikacije za poslovanje.
3. Raziščimo, ali je odzivni čas spletne aplikacije na produkciji povezan s tehnologijo, v kateri je bila aplikacija razvita na strežniški strani.
 - (a) Za vsako od programskih tehnologij izračunaj vzorčno povprečje in vzorčni standardni odklon spremenljivke *Odziv*. Primerjaj dobljene rezultate med skupinami.
 - (b) Na stopnji značilnosti 0,05 preveri, ali obstajajo statistično značilne razlike v odzivnem času med aplikacijami, razvitimi v tehnologijah *Node.js*, *Spring* in *Django*.
 - (c) Na stopnji značilnosti 0,05 preveri, pri kateri tehnologiji so aplikacije najhitrejše (tj. imajo najmanjši povprečni odzivni čas).
 - (d) Ustvari novo spremenljivko *Čas*, ki bo odzivne čase razvrstila v naslednje razrede:

- 1 - odzivni čas do vključno 200 ms;
 - 2 - odzivni čas od 200 ms do vključno 250 ms;
 - 3 - odzivni čas od 250 ms do vključno 300 ms;
 - 4 - odzivni čas od 300 ms do vključno 350 ms;
 - 5 - odzivni čas od 350 ms.
- (e) Na stopnji značilnosti 0,05 preveri, ali obstaja povezava med izbrano programsko tehnologijo in odzivnim časom aplikacije na produkcijo.
4. Preverjamo, ali velikost razvojne ekipe vpliva na odzivni čas spletne aplikacije na produkcijo.
- (a) Podatke predstavi z razsevnim diagramom in na oko oceni, ali je povezava med spremenljivkama videti približno linearna.
- (b) Na stopnji značilnosti 0,01 preveri, ali obstaja statistično značilna linearna povezanost med velikostjo ekipe in odzivnim časom aplikacije.
- (c) V razsevni diagram vriši vzorčno regresijsko premico in zapiši enačbo te premice, ki ocenjuje odzivni čas na produkciji glede na velikost razvojne ekipe. Pojasni, kaj nam povesta a in b .
- (d) Kolikšen odzivni čas aplikacije bi pričakovali pri osem oz. 40 članski ekipi?
- (e) Ocenimo kakovost modela. Kako dober je ta regresijski model za razlago odzivnega časa?
- (f) Na stopnji značilnosti 0,05 oceni, ali ima velikost ekipe statistično značilen vpliv na odzivni čas aplikacije?
5. Ali je pokritost aplikacije z avtomatiziranimi testi povezana s številom kritičnih napak v produkciji?
- (a) Na stopnji značilnosti 0,05 preveri, ali obstaja statistično značilna povezanost med pokritostjo aplikacije z avtomatiziranimi testi in številom kritičnih napak v produkciji.
- (b) Ali lahko zapišemo linearni model, ki napoveduje število kritičnih napak glede na testno pokritost?
6. Ali je odzivni čas aplikacije na produkciji povezan s številom napak v produkciji?
- (a) Vizualiziraj odnos med spremenljivkama *Odziv* in *Napake* z razsevnim diagramom. Na podlagi grafičnega prikaza ocni, ali je povezava med spremenljivkama linearna ali nelinearna?
- (b) Na stopnji značilnosti 0,01 preveri, ali obstaja statistično značilna povezanost med odzivnim časom aplikacije in številom napak v produkciji?
- (c) Ali lahko na stopnji značilnosti 0,01 sklepamo, da hitrejše aplikacije povzročajo manj napak v produkciji?
- (d) Zapiši enačbo regresijske premice za napoved odzivnega časa v odvisnosti od števila napak v produkciji. Pojasni, kaj nam pove regresijski koeficient in kako interpretirati njegovo vrednost.
- (e) Preveri kakovost regresijskega modela na podlagi regresijskega koeficienta R^2 .

7. Ali je velikost ekipe povezana s številom napak v produkciji?
- (a) Prikaži odnos med spremenljivkama *Odziv* in *Napake* z razsevnim diagramom. Na podlagi grafičnega prikaza oceni, ali obstaja povezava med spremenljivkama?
 - (b) Na stopnji značilnosti 0,01 preveri, ali obstaja statistično značilna povezanost med odzivnim časom aplikacije in številom napak v produkciji?